

Data Base Analysis — README

Visão geral do projeto · limpeza dos dados · Machine Learning no navegador

Data Base Analysis

Dashboard Interativo — Nascidos Vivos Brasileiros (2019–2023)

Sobre o projeto

O Data Base Analysis é um dashboard interativo que visualiza dados de nascidos vivos no Brasil, usando informações reais do SINASC (Sistema de Informação sobre Nascidos Vivos) do DataSUS, cobrindo o período de 2019 a 2023.

O projeto surgiu como atividade avaliativa da disciplina de Banco de Dados, mas foi pensado para ir além de um simples trabalho acadêmico. A ideia era criar uma ferramenta visual que permitisse explorar indicadores de saúde pública de forma acessível — sem precisar lidar com planilhas enormes ou arquivos brutos.

O que ele faz

Com dados de mais de 6 mil nascidos vivos, o dashboard permite:

- Explorar por região — Compare os 5 blocos regionais do Brasil (Norte, Nordeste, Centro-Oeste, Sudeste, Sul) e veja como nascimentos, taxas de cesárea, baixo peso e prematuridade variam entre eles.
- Acompanhar a evolução temporal — Série histórica de 2019 a 2023 para identificar tendências de natalidade e variações ao longo dos anos.
- Conhecer o perfil das mães — Segmentação por faixa etária, mostrando que a maioria das mães está na faixa adulta (20–34 anos), com 11% sendo adolescentes.
- Analisar por sexo — Distribuição quase equilibrada entre nascimentos masculinos (50,9%) e femininos (46,8%).
- Detalhar estado por estado — Drill-down completo para todas as 27 UF's com indicadores específicos.

Como funciona a limpeza dos dados

Dados reais do DataSUS vêm com imperfeições. Foram identificados e removidos 570 registros (9,4%) que apresentavam problemas:

- Pesos de nascimento fora do esperado ou ausentes
- Idades maternas incompatíveis com a faixa biológica
- Siglas de estados inválidas
- Registros duplicados

O que sobrou são 5.510 registros limpos, prontos para análise.

O dashboard oferece

- 7 tipos de gráficos — Barras, linhas, donut, tabela e mais
 - Filtros combináveis — Região, ano, faixa etária e sexo juntos
 - Modo claro e escuro — Para gostar de cada um
 - 3 idiomas — Português, Inglês e Espanhol
 - Terminal interativo — Um simulador de comandos em R, SQL e CMD para quem quiser brincar
 - Responsivo — Funciona no celular e no desktop
-

Machine Learning no navegador

Além do dashboard descritivo, o projeto tem uma seção de Modelagem Preditiva que roda 100% no navegador (sem backend):

- Calculadora de risco — Sliders de idade da mãe, semanas de gestação e consultas de pré-natal + chips de sexo, região e ano. Em tempo real, mostra a probabilidade de baixo peso ao nascer, um gauge com o limiar de Youden, o badge de risco, os fatores de maior influência e um indicador de impacto ($\pm$ p.p.) ao lado de cada campo.
- Resultados dos modelos — Importância SHAP das features, comparativo de 4 modelos (Dummy, Regressão Logística, Random Forest, XGBoost) com validação 5-fold e curvas ROC out-of-fold, com abas para baixo peso e prematuridade.
- Como funciona — Como a Regressão Logística venceu o XGBoost (o sinal do dataset é majoritariamente linear), os coeficientes + scaler são exportados para `src/data/ml.ts` e o cálculo $\text{sigmoid}(w \cdot x + b)$ é feito no próprio navegador.

Modelo em produção: Regressão Logística — ROC-AUC 0.785 no baixo peso · limiar de Youden 0.544 · treinado em 5.379 registros completos (os 131 com campos ausentes foram descartados).

Projeções 2024–2025 (método top-down)

A seção de modelagem também inclui uma projeção exploratória de tendência para 2024–2025, com banda de incerteza honesta (a especificação completa está em `ml/PROJECÃO_TECN_DESIGN.md`).

O método, em 3 camadas:

Total — Regressão linear OLS do total de nascimentos sobre o ano, com intervalo de predição de 95% (2025: 1.100 [941–1.259]).

Participações (%) — Share de cada região, faixa etária e sexo, ancorada no último valor observado (2023) + drift, normalizada para somar 100%.

Reconciliação — Valor de cada grupo = total $\times$ share $\rightarrow$ as dimensões somam exatamente o total projetado.

A incerteza é propagada por método delta e cresce com o horizonte — por isso a projeção fica limitada a 2 anos (com 5 pontos anuais, prever 5 anos não seria estatisticamente defensável). O método foi validado com holdout (treino 2019–2022, teste em 2023): erro de $-2,0\%$ no total.

Destaques encontrados: participação do Norte em declínio ($-0,39$ p.p./ano, $p = 0,044$) e de mães 35+ ($-0,75$ p.p./ano, $p = 0,059$) — os únicos sinais de tendência detectáveis em 5 anos de dados.

No front, o bloco exibe o gráfico (histórico sólido + projeção tracejada + banda sombreada), filtros por dimensão, alternância entre nascimentos e participação % e os cards de validação.

Como rodar

Precisa ter o Node.js versão 18 ou superior instalado.

```
git clone
https://github.com/manoelja/data-base-analysis.git
cd data-base-analysis
npm install
npm run dev
```

Depois é só abrir <http://localhost:5173> no navegador.

Tecnologias

O projeto foi construído com React + TypeScript, usando Vite como ferramenta de build. Os dados foram processados em R com persistência em SQLite, e o dashboard conta com animações via Framer Motion e internacionalização com i18next.

A modelagem preditiva usa Python (scikit-learn, xgboost, shap, scipy), com scripts em ml/ que exportam os modelos e projeções para arquivos TypeScript estáticos consumidos pelo navegador:

```
| Script | Gera | Conteúdo |
| `ml/export_frontend_data.py` | `src/data/ml.ts` | Modelo
LR (scaler + coeficientes + limiar), SHAP, ROC, métricas |
| `ml/export_forecast.py` | `src/data/forecast.ts` |
Projeção top-down 2024-2025 com intervalo de 95%,
validação e destaques |
```

Desenvolvido com  para análise de dados de saúde pública